

# Лекция 9

Линейная регрессия с точки зрения МО. Задача классификации

---

**Курс:** Введение в DS на УБ и МиРА (весна, 2022)

**Преподаватель:** Владимир Омелюсик

30 мая 2022 г.

## В предыдущих сериях

- Тестирование гипотез в линейной регрессии.
- Основные понятия машинного обучения.
- Виды задач машинного обучения.

- Всё то же самое, что обсуждали до этого.
- Важно только качество предсказаний.
- Проблемы с обучением по формулам:

$$\hat{\beta} = (X^T X)^{-1} X^T y$$

- Если матрица  $(X^T X)$  необратима, то будут проблемы с вычислениями.
- Произведение матриц – долгая операция.

# Обучение: градиентный спуск

# Обучение: градиентный спуск

- В многомерном случае рассчитываем градиент:

$$\nabla_x f(x) = \left( \frac{df}{dx_1}, \dots, \frac{df}{dx_d} \right)$$

- Например, градиент MSE:

$$\nabla_{\beta} MSE = \frac{2}{N} X^T (Xw - y)$$

- Градиентный спуск для обучения:

$$\hat{\beta}_{t+1} = \hat{\beta}_t - \alpha \nabla_{\beta} MSE(\hat{\beta}_t),$$

где  $\alpha > 0$  – длина шага.

# Алгоритм градиентного спуска

1. Выбираем начальное приближение  $\beta_0$ .
2. Повторяем

$$\hat{\beta}_{t+1} = \hat{\beta}_t - \alpha \nabla_{\beta} MSE(\hat{\beta}_t),$$

3. Останавливаемся, если

$$\|\hat{\beta}_t - \hat{\beta}_{t-1}\|_2 \leq \varepsilon$$

# Проблема градиентного спуска

- Градиентный спуск находит только локальные минимумы.
- Решение: мултистарт

$$\beta_{t+1} = \beta_t - \alpha \nabla_{\beta} MSE(\beta_t),$$

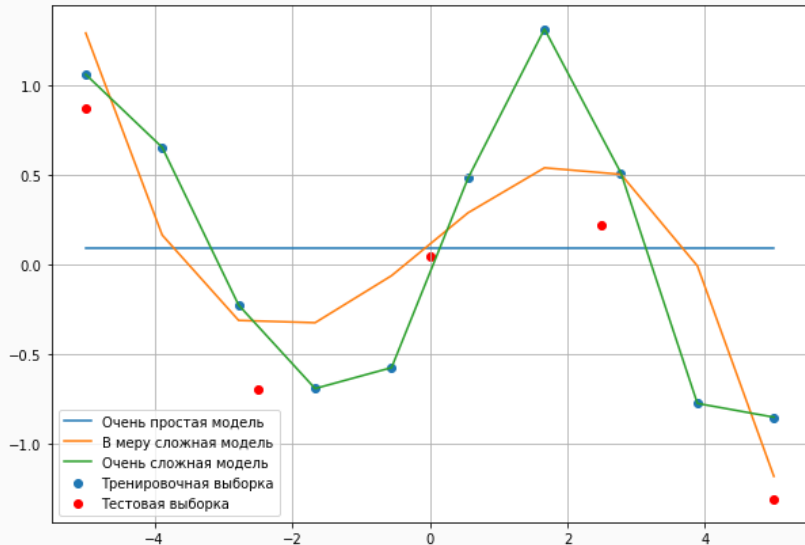
- Позволяет контролировать скорость обучения.
- Если сделать слишком большой, можно «перепрыгнуть» минимум.
- Гиперпараметр, нужно подбирать.



# Обобщающая способность модели

- Обобщающая способность – способность модели давать корректные предсказания на новых данных, не участвовавших при обучении.
- Недообучение – ситуация, когда модели не удалось правильно «запомнить» зависимости в данных. В этом случае качество будет низким как на обучающей выборке, так и на тестовой.
- Переобучение – ситуация, когда модель идеально «запомнила» свойства обучающей выборки, но не общие зависимости в ней. В этом случае качество будет высоким на обучающей выборке, но низким на новых данных.

# Обобщающая способность модели



- Наблюдение: большие веса могут свидетельствовать о переобучении.

$$\hat{y}_i = 0.2 + 1495.23x_i + \dots,$$

если  $x_i$  – вес человека в кг, а  $y_i$  – рост человека в см – странно.

- Идея – штрафовать большие веса.

- Добавим к функции потерь регуляризатор. Например,

$$\|\beta\|_2^2 = \sum_{j=1}^k \beta_j^2$$

- Новая функция потерь:

$$\|y - X\beta\|_2^2 + \lambda\|\beta\|_2^2,$$

где  $\lambda$  – коэффициент регуляризации.

- Запускаем градиентный спуск на новой функции потерь.
- Важно не включать в регуляризатор  $w_0$ .

Всё те же, что были для статистики:  $MSE$ ,  $MAE$ ,  $R^2$ , ...

- Дано:  $X$  и  $y$ .
- Решаем задачу многоклассовой классификации: каждое наблюдение может относиться к одному из  $K$  классов:  $y_i \in \{1, 2, \dots, K\}$ .

### Гипотеза компактности

У «похожих» друг на друга объектов будут «похожие» ответы.

- Как определить похожесть? Для числовых признаков, например, так:

$$d(x_1, x_2) = \sqrt{\sum_{j=1}^k (x_1^j - x_2^j)^2}$$

1. **Обучение.** В kNN отсутствует. На этапе обучения происходит запоминание обучающей выборки  $X$ ,  $y$ .
2. **Предсказание.**
  - 2.1 Пусть нужно сделать предсказание для нового объекта  $x_i$ . Отсортируем объекты обучающей выборки по расстоянию до этого объекта.

$$d(x_i, x_{(1)}) \leq d(x_i, x_{(2)}) \leq \dots$$

- 2.2 Предсказываем самый популярный класс среди  $k$  ближайших соседей.

$$\hat{y}_i = \arg \max_C \sum_{i=1}^k [y_{(i)} = C]$$





- Числовые признаки.
  - Евклидово расстояние.

$$d(x_1, x_2) = \sqrt{\sum_{j=1}^k (x_1^j - x_2^j)^2}$$

- Манхэттэнское расстояние.

$$d(x_1, x_2) = \sum_{j=1}^k |x_1^j - x_2^j|$$

- Категориальные признаки.
  - Считающее расстояние.

$$d(x_1, x_2) = \sum_{j=1}^k [x_1^j \neq x_2^j]$$

- Простой метод, основанный на расчётах расстояний.
- Гиперпараметры: число соседей  $k$  и функция расстояния.
- Проблема: поиск соседей может занимать долгое время.

- Дано:  $X$  и  $y$ .
- Решаем задачу бинарной классификации:  $y_i \in \{-1, 1\}$ .









# Логистическая функция потерь





# Мягкая и жёсткая классификация

